

## 当数据迫使理论改道：开普勒、伽利略与牛顿

Agentic Data Scientist 并不是凭空出现的新职业。它试图自动化的，是一条在科学史中反复出现的发现链：提出问题、取得证据、创造解释，再让解释接受检验。下面三个故事不是完整的科学革命史，却分别揭示了这条链上的关键转折。

### 1601–1609 ·开普勒：不能被忽略的 8 角分

第谷把解释火星轨道的任务交给开普勒。当时连开普勒也相信，天体应沿“完美”的圆运动。他构造的圆轨道模型已经非常接近观测，但在某些位置仍相差 6 到 8 角分。换一个研究者，这可能只是可以修饰掉的残差；开普勒却相信第谷的观测精度，拒绝让漂亮理论压过数据。

这 8 角分迫使他离开圆轨道，穿过大量失败计算，最终得到椭圆轨道与面积定律，并在 1609 年出版《新天文学》。这个故事的核心不是“拟合出了一个更好的曲线”，而是知道什么时候应该怀疑模型背后的基本假设。[H1,H2]

### 1610 ·伽利略：先创造一种新的观察方式

《星际信使》记录了望远镜下凹凸不平的月面、肉眼不可见的恒星，以及木星附近数个亮点在连续夜晚中的位置变化。尤其是木星卫星的序列观测，给出了“有些天体并不围绕地球运行”的直接实例。

望远镜在这里不只是把旧计算做得更快。它改变了什么可以成为数据，也改变了哪些问题能够被提出。对今天的 ADS 而言，数据源、传感器、检索工具和实验环境同样不是被动输入；创造新的观测方式，本身就是解决问题和创新的一部分。[H3]

### 1684–1687 ·牛顿与哈雷：发现也需要协作系统

开普勒描述了行星怎样运动，却不知道是什么力量造成这种运动。1684 年，哈雷就轨道问题拜访牛顿，推动他把几页回答扩展成《自然哲学的数学原理》。1687 年出版的《原理》用运动定律和万有引力把地面与天空纳入同一套可推演框架。

出版过程还有一个真实的插曲：皇家学会此前在《鱼类史》上花费过多，难以兑现出版经费，哈雷接手推进并承担费用。科学创新从来不只是“一个天才和一个公式”；好问题、前人成果、计算方法、协作者和传播机制共同构成了发现的基础设施。[H4]

三个故事给出同一条线索：数据科学发现不是“数据进、答案出”。它会因为异常重新提问，因为新工具获得新证据，因为旧理论不足而创造新结构，并把结果重新放回观测中检验。

[H1] NASA, Orbits and Kepler's Laws ; [H2] Stephenson, Kepler, DSB ; [H3] Galileo, Sidereus Nuncius, 1610, Library of Congress ;

[H4] Royal Society, Principia manuscript history。

## 从验证一项解释，到自动化发现循环

开普勒、伽利略和牛顿留下的是发现范式；此后的统计学与数据科学，则逐渐把“怎样从数据获得可靠认识”变成一套可以教授、复查和改进的方法。

### 1854 · 约翰·斯诺：地图不是结论，干预也不是自动证明

伦敦霍乱调查常被简化成一个英雄故事：斯诺画出死亡地图，拆掉宽街水泵把手，疫情因此结束。真实过程更值得数据科学家学习。他把病例位置、饮水来源、异常个案和不同供水公司的人群放在一起，形成“霍乱经受污染的水传播”的证据链。

更重要的是，斯诺在 1855 年的原始报告中承认：9 月 8 日拆除把手以前，新发病例已经明显下降，因此无法仅凭时间先后判断水泵停用的效果。这不是故事的缺陷，而是验证能力的示范：区分一种有证据支持的机制，与某个干预究竟造成了多大效果。[H5]

### 1923–1962 · Fisher 与 Tukey：验证和探索成为方法

Fisher 在 Rothamsted 农业试验中面对的不是“拿到数据后选哪个检验”，而是怎样安排田块与处理，才能提高精度并得到有效的误差估计。他 1926 年的论文把实验设计的逻辑写成系统原则。**可靠性开始于数据产生之前**，而不是分析完成之后再补一个  $p$  值。[H6]

1962 年，Tukey 在《数据分析的未来》中把数据分析主张为一门独立的经验性活动。此后，探索性分析、计算、可视化、预测与可复现性不断扩大传统统计建模的边界。数据科学逐渐从“使用某种模型”，转向研究**从问题到证据的整个过程**。[H7,H8]

### 2024–2026 · 当机器开始生成假设，瓶颈转向验证

2024 年的 The AI Scientist 已能生成研究想法、编写代码、运行实验并模拟评审；2025 年的 AI Co-Scientist 进一步用生成、反思、排序和演化来迭代候选假设。这些工作说明，研究流程的多个环节已经可以被 Agent 化，但它们并没有证明机器已经成为可靠的自主科学家。[H9,H10]

到 2026 年，Google DeepMind 用“验证瓶颈”概括新的矛盾：Agent 可以快速制造大量猜想，现实实验、独立复现和同行审查却仍然昂贵而缓慢。今天最稀缺的能力不再只是生成答案，而是**提出值得验证的问题，并建立能够淘汰错误答案的证据系统**。[H11]

这条历史线最终回到本章的定义：所谓 Agentic Data Scientist，不是把历史上的工具装进一个聊天框，而是让提问、求解、创新与验证依据证据形成新的行动循环。

[H5] Snow, On the Mode of Communication of Cholera, 1855 ; [H6] Fisher, The Arrangement of Field Experiments, 1926 ; [H7] Tukey, The Future of Data Analysis, 1962 ; [H8] Donoho, 50 Years of Data Science, 2017 ; [H9] Lu et al., The AI Scientist, 2024 ; [H10] Google Research, AI Co-Scientist, 2025 ; [H11] Google DeepMind, Validation Bottleneck, 2026.

# 什么是 Agentic Data Scientist ?

一个真正的数据科学问题，通常不会以“这里有一张表，请预测目标列”的形式出现。它更可能始于一个异常、一项决策，或者一句尚未说清楚的目标：为什么用户正在离开？怎样判断一种治疗是否有效？哪些现象值得继续研究？

这类问题的困难不只是计算。研究者首先要发现什么问题值得问，然后决定怎样解决；现有办法失效时，需要创造新的假设、数据或方法；最后还要设计一种可能证明自己错了的验证。这四种能力，才是“Data Scientist”的专业内核。[1,2]

## 本书的定义

**Agentic Data Scientist ( ADS )** 是能够自主完成数据科学发现循环的 AI 系统：它能从目标与现象中提出有价值且可检验的问题，构造并执行解决方案，在现有数据和方法不足时产生新的假设或解法，并主动寻找能够验证或推翻自身结论的证据。系统根据验证结果决定下一步：继续求解、改变方法、重新提出问题，或者承认证据不足并停止。

## 四种一级能力

| 能力   | 真正要完成的事                                 | 不等于                    |
|------|-----------------------------------------|------------------------|
| 提出问题 | 从现象、矛盾和目标中发现未知，把它表述成重要、可回答、可证伪的问题       | 改写用户的问题，或补齐任务模板        |
| 解决问题 | 在信息和资源不完备时形成假设，寻找证据，设计路径并执行；结果不符时能够换路   | 按固定流程调用 SQL、Python 或模型 |
| 创新   | 当已有方案不足时，提出新的假设、代理数据、表示、算法、实验或工具，扩大可解空间 | 生成更多候选答案，或使用更复杂的模型     |
| 验证   | 主动寻找反例和替代解释，检查识别、稳健性、不确定性与复现性，让结论接受证据约束 | 只报告一个较高分数，或选择支持自己的指标   |

## 为什么“验证”必须单独成为一种能力？

生成一个解释并不困难，困难的是说明：什么证据会使这个解释不再成立？如果系统只会寻找支持自己的结果，它完成的是论证，不是科学。验证能力要求系统设计对照、留出集、消融、敏感性分析、外部复现或现实实验，并把失败送回下一轮提问与求解。[3,4]


因此，本书不以“是否调用工具”判断 ADS。工具调用只是执行手段；提出问题、创造解法并检验自己，才把一个数据 Agent 推向数据科学家。

[1] 郑宇，《数据科学家》，CCCF 17(12), 2021；[2] Donoho, *50 Years of Data Science*, 2017；[3] Popper, *The Logic of Scientific Discovery*, 1959；[4] Shmueli, *To Explain or to Predict?*, 2010。

# Agentic：让四种能力形成发现闭环

“会提问、会建模、会检查”仍可能只是四个彼此分离的功能。**Agentic** 的含义是：系统保存研究状态，观察行动结果，并依据证据决定接下来调用哪一种能力。验证失败后，它不只是重跑程序，而能回到假设、数据、方法甚至原问题本身。

图 1.1 数据科学发现不是直线流水线



**Agentic 的最低含义**  
系统必须能够根据新证据改变研究控制流：选择继续求解、调用新的数据与工具、创造候选解法、加强验证、退回重提问题，或停止。若所有步骤和分支都由人预先写死，它是 Workflow；若只在既定目标和搜索空间内优化，它更接近 AutoML。[5,6]

## 不要再把三个层次混在一起

| 层次           | 内容                      | 它回答的问题             |
|--------------|-------------------------|--------------------|
| 科学家能力        | 提出问题、解决问题、创新、验证         | 为什么它不只是分析工具？       |
| 数据科学工作对象     | 行业问题、数据、模型与算法、计算平台      | 它在哪些对象上思考和行动？      |
| Agentic 运行机制 | 状态与记忆、规划与行动、工具与环境、反馈与反思 | 四种能力如何持续接力并根据证据改道？ |

郑宇所说的“站在平台上看问题、想数据、关联模型”，刻画的是数据科学家的**端到端工作对象**；它非常重要，但不是最高层能力分类。LLM、Agent、Harness、数据与计算环境，则是实现这些能力的技术条件，而不是“科学家”一词的定义。[1,7]

**一个可以被反驳的判断**  
如果系统面对失败只会换提示词、重试工具或继续调参，却不能重新审视“问题是否问对、证据是否足够、现有方法是否需要创新”，那么无论调用多少工具，它都还不是完整意义上的 ADS。

[5] Lu et al., *The AI Scientist*, 2024 ; [6] Gottweis et al., *Towards an AI Co-Scientist*, 2025 ; [7] Chen et al., *LLM-based Data Science Agent: A Survey*, 2025。

# 系统边界：能做到，不等于可以去做

四种能力回答“系统是否像一名数据科学家”；系统边界回答另一个问题：**这名数据科学家在当前任务中可以观察什么、改变什么，何时必须停下，以及谁承担后果。**能力越强，不代表权限越大，更不代表责任可以交给模型。<sup>[8,9]</sup>

## 能力、自治、权限与责任是四件不同的事

| 概念                | 它回答什么                     | 一个系统可能出现的情况       |
|-------------------|---------------------------|-------------------|
| 能力 capability     | 它能否提出、解决、创新和验证？           | 能设计可靠实验，但不会自主执行   |
| 自治 autonomy       | 它能连续决定多少步，何时需要人介入？        | 可在沙箱里自行探索，发布前必须审批 |
| 权限 authority      | 它被允许读取哪些数据、调用哪些工具、改变哪些状态？ | 可读脱敏数据，不能接触生产库    |
| 责任 accountability | 谁批准、监督并对结论及外部影响负责？        | 研究负责人批准实验并承担发表责任  |

**一个可执行的系统边界必须写清五件事**  
观察：允许读取哪些数据、文献、日志与反馈；行动：允许查询、写入、实验、部署或联系谁；资源：时间、算力、费用、凭据和重试上限；升级与停止：哪些风险、证据或预算条件触发人工批准或终止；责任：谁对数据使用、研究结论和现实后果负责。

## 定义边界：什么还不能叫 ADS？

| 系统形态                   | 它已经能做什么                 | 距离 ADS 还缺什么                        |
|------------------------|-------------------------|------------------------------------|
| 分析助手                   | 回答问题，生成 SQL、代码、图表或解释    | 问题、行动与验证主要由人完成                     |
| Workflow / AutoML      | 执行固定流程，或在给定目标与搜索空间内优化   | 不能重提问题，也通常不能创造搜索空间之外的解法            |
| 数据 Agent               | 调用工具完成多步数据任务，并依据结果调整计划  | 若问题始终由人给定，且不具备创新与主动证伪，仍只是执行型 Agent |
| Agentic Data Scientist | 自主组织提问、求解、创新和验证，并依据证据改道 | 仍受明确权限、批准和责任边界约束                   |

**四个可检验的最低判据**  
提问：它能提出用户没有直接给出的新问题，并说明为什么值得研究吗？求解：当基线失败时，它会改变假设、数据或方法，而不只是重试吗？创新：它能提出已有方案之外的新解法，并与强基线比较吗？验证：它能事先说明什么证据会推翻自己的结论，并真正执行检查吗？  
四问都能留下可审查的证据，才接近本书所说的 ADS。高自治、长轨迹或大量工具调用，都不能替代这四项判据。

[8] Feng et al., *Levels of Autonomy for AI Agents*, 2025 ; [9] NIST, *AI Risk Management Framework 1.0*, 2023 ; 参见 Kapoor et al., *AI Agents That Matter*, 2024。